随机优化算法的形式化验证：主要数学卡点与难点记录

以 SVRG 外层循环收敛性为例（Lean 4 / Mathlib 4）

Thomas Wang

2026 年 3 月 13 日

目录

1 背景：我们在做什么

这个项目的目标是用 Lean 4（配合 Mathlib 数学库）把随机优化算法的收敛性证明全部机器验证一遍——也就是让计算机确认每一步推导都是对的，不只是”看起来对”。

目前已经形式化或正在形式化的算法包括：SGD、SubgradientMethod、WeightDecaySGD、ProjectedGD、SVRG、SVRGOuterLoop。

1.1 代码的三层结构

为了方便复用，代码被分成三层：

Layer 0（`Lib/Layer0/`） 最底层的纯数学事实，比如凸函数的一阶条件、梯度范数估计等。这些定理跟”随机”完全没关系，只是 Lean 里还缺的基础凸分析工具。

Layer 1（`Lib/Layer1/`） 抽象的随机下降元定理。只要一个更新规则满足”无偏性 + 有界方差 + 迭代点与当前样本独立”这三条，就可以直接调用这里的定理得到收敛率。

Layer 2（`Algorithms/`） 具体算法文件。把算法的具体设置”桥接”到 Layer 1 的抽象框架里，然后调用 Layer 1 的定理得到结论。

还有一个**胶水层**（`Lib/Glue/`），专门存放连接 Mathlib 和算法证明之间的”桥接引理”——可积性包装器、方差缩减不等式、独立性组合引理等。

1.2 Gap 的三种类型

每次证明卡住，先判断是哪类 Gap：

Level 1 Mathlib 完全没有这个结论，需要从头证。

Level 2 Mathlib 有相关的零件，但没有把它们组合起来的引理，需要写一个桥接引理。

Level 3 Mathlib 有这个定理，但类型签名或形式跟目标不完全匹配，需要写一个薄封装。

随机优化证明里 **Level 2 最常见**，Level 3 最高频但个个都很小。

2 Layer 0：Hilbert 空间的一阶条件

这是整个证明体系的地基。Mathlib 4 有标量版的一阶条件（`ConvexOn.le_slope_of_hasDerivAt`），但完全没有 Hilbert 空间的多元版本。下面四个定理都是 Level 1 Gap，全部在 `Lib/Layer0/ConvexFOC.lean` 里手工证明。

定理 2.1 (凸函数一阶条件)**.** *设 E 是实 Hilbert 空间，$f : E \to \mathbb{R}$ 在全空间凸且处处可微，梯度为 ∇f。则对所有 $x, y \in E$：*

$$f(y) \;\geq\; f(x) + \langle \nabla f(x),\, y - x \rangle.$$

Lean 卡点. 证明思路是把多元问题降到一维：令 $g(t) = f(x + t(y - x))$，证 $g'(0) = \langle \nabla f(x), y - x \rangle$，再用 Mathlib 的标量 FOC 得到 $g(1) \geq g(0) + g'(0)$。

主要麻烦在于 Lean 里描述这条线段需要用 `AffineMap.lineMap`，而它展开的形式和直接写 $x + t(y - x)$ 不一样，需要一个 `ext + simp + abel` 来对齐——看起来很小，但容易卡住。

定理 2.2 (强凸一阶条件)**.** *设 f 是 μ-强凸且处处可微。则对所有 $x, y \in E$:*

$$f(y) \;\geq\; f(x) + \langle \nabla f(x),\, y - x \rangle + \frac{\mu}{2}\,\|y - x\|^2.$$

Lean 卡点. 关键想法：令 $h = f - \frac{\mu}{2}\|\cdot\|^2$，那么 h 是普通凸函数，对 h 用定理 **??**，再加回减掉的那项就行。

卡点在于计算 $\nabla h = \nabla f - \mu\,\mathrm{id}$。Mathlib 里 $\|\cdot\|^2$ 的导数由 `hasStrictFDerivAt_norm_sq` 给出，但它返回的是 $2 \cdot \mathrm{innerSL}_{\mathbb{R}}\, w$ 这种连续线性映射形式，需要手动算 smul 再用 `convert` 对齐类型，非常容易出类型不匹配的错误。

推论 2.3 (凸函数极小值点的内积下界)**.** *设 f 凸，w^* 是极小值点，则:*

$$f(w) - f(w^*) \;\leq\; \langle \nabla f(w),\, w - w^* \rangle.$$

推论 2.4 (强凸极小值点的内积下界)**.** *设 f 是 μ-强凸，w^* 是极小值点，则:*

$$\langle \nabla f(w),\, w - w^* \rangle \;\geq\; \frac{\mu}{2}\,\|w - w^*\|^2.$$

推论 **??** 是所有强凸收敛证明里出现收缩因子 $(1 - \eta\mu)$ 的直接来源。

定理 2.5 (梯度范数估计)**.** *设 f 是 L-光滑的，极小值点为 w^*，则:*

$$\|\nabla f(w)\| \;\leq\; L\,\|w - w^*\|.$$

Lean 卡点. 这个定理本身很直接，但 Lean 里有**两个独立的 API 错位**（Level 3 Gap）:

问题一：全局极小 → 局部极小的类型不匹配。想用 `IsMinFilter.filter_mono` 把全局极小转成局部极小，需要证 `nhds wStar ≤ Filter.principal univ`。但 Lean 不会自动把 `Filter.principal univ` 和 ⊤ 等同，所以直接写 `le_top` 类型不对。解法：绕过去，直接用 `Filter.Eventually.of_forall hmin`——因为 $f(w^*) \leq f(y)$ 对所有 y 成立，所以在任何 filter 下都"eventually" 成立，自然就是 `IsLocalMin`。

问题二：dist 版本 vs. 范数版本。`LipschitzWith.dist_le_mul w wStar` 给出的是 $\mathrm{dist}(\nabla f(w), \nabla f(w^*)) \leq L \cdot \mathrm{dist}(w, w^*)$，但目标要的是 $\|\nabla f(w) - \nabla f(w^*)\| \leq L\|w - w^*\|$。解法:

```
have h := hsmooth.dist_le_mul w wStar
rwa [dist_eq_norm, dist_eq_norm] at h
```

看起来只是两行，但如果不知道 `dist_eq_norm` 这个引理，会在这里卡很久。

3 胶水层：SVRG 方差缩减

SVRG 相对于普通 SGD 的核心优势是" 方差缩减"——通过使用快照梯度 $\nabla F(\tilde{w})$，把每步更新的方差从 $O(\sigma^2)$ 降到跟 $\|\tilde{w} - w^*\|$ 相关的量，从而实现线性收敛。下面的定理把这个直觉精确化。

定理 3.1 (SVRG 方差缩减，`svrg_variance_reduction`)**.** *设样本集 S 是有限的，均匀采样分布为 ν，快照点为 $\tilde{w}$，SVRG oracle 的梯度估计为：*

$$v(w, s) \;=\; \nabla_s l(w) - \nabla_s l(\tilde{w}) + \nabla F(\tilde{w}).$$

若对所有 $s \in S$，$w \in E$ 有逐点界：

$$\|v(w, s)\|^2 \;\le\; 4L\big(F(w) - F^*\big) + 2\|\nabla F(\tilde{w}) - \nabla F(w^*)\|^2,$$

则取 ν-期望后同样成立：

$$\mathbb{E}_{s\sim\nu}\big[\|v(w, s)\|^2\big] \;\le\; 4L\big(F(w) - F^*\big) + 2\|\nabla F(\tilde{w}) - \nabla F(w^*)\|^2.$$

Lean 卡点. **为什么需要 `[Fintype S]`？** Lean 里的 Bochner 积分默认是连续测度上的。要把期望转成有限平均，必须有一个引理说" 在有限集上的均匀测度下，积分 = 算术平均"。这需要 `[Fintype S]` 类型类实例。

证明路线：先用 `h_unif` 把积分转成 $\frac{1}{|S|}\sum_s$，再用 `Finset.sum_le_sum` 逐点应用已有的界，最后 `field_simp` 约掉 $\frac{1}{|S|} \cdot |S| = 1$。整体不难，但需要注意 `Fintype.card` 转 $\mathbb{R}$ 时要显式 cast。

意义：这个不等式的右边当 $\tilde{w} \to w^*$ 时趋于零，这正是 SVRG 能达到线性收敛而不是 SGD 的次线性收敛的根本原因。

4 算法层：最难的卡点——独立性与多轮结构

4.1 过程定义

SVRG 外层循环定义两个递归过程：

内层过程（epoch k 的 m 步 SGD）：

$$\texttt{svrgInnerProcess}(w_k, \nabla F(w_k), k, m)(t, \omega) \;=\; \texttt{sgdProcess}\big(w_k, \eta, \underbrace{\nabla_s l(\cdot) - \nabla_s l(w_k) + \nabla F(w_k)}_{\text{SVRG oracle}}, \xi_{km+\cdot}\big)(t, \omega).$$

外层过程（每个 epoch 的起始点序列）：

$$w_0 = w_{\text{init}}, \qquad w_{k+1}(\omega) \;=\text{（第 } k \text{ 个 epoch 跑完 } m \text{ 步后的终点）}.$$

4.2 最关键的引理：epoch 独立性

引理 4.1 (Epoch 独立性，`outerProcess_indepFun_epoch`)**.** *对每个 epoch 索引 k 和偏移 $t < m$:*

$$w_k \perp_P \xi_{km+t}.$$

即：第 k 个 epoch 的起始点 w_k 与该 epoch 内部用到的样本 ξ_{km+t} 相互独立。

为什么这个引理是整个证明的关键？ 因为要对内层循环用 Layer 1 的元定理，就需要对条件期望做分解：$\mathbb{E}[f(w_{k+1}, \xi)] = \mathbb{E}[\mathbb{E}[f(w_{k+1}, \xi) \mid w_k]]$，而这一步需要 $w_k \perp \xi_{km+t}$ 才成立。没有这个独立性，epoch 收缩那步就走不下去。

证明的数学直觉： w_k 是 $\xi_0, \ldots, \xi_{km-1}$ 的函数，而 ξ_{km+t}（$t < m$）的下标 $\geq km$，由样本流的互独立性，它们应该是独立的。

为什么 Lean 里卡住了？ 直觉上"w_k 依赖的样本下标 $< km$，而 ξ_{km+t} 的下标 $\geq km$，所以独立"——这个推理在 Lean 里需要如下引理：

引理 4.2 (独立性组合，Mathlib 缺失)**.** *设 $X : \Omega \to E$ 可测，$Y : \Omega \to F$ 可测。若存在一族可测随机变量 $\{Z_s\}_{s \in I}$ 使得：*

- *X 关于 $\sigma(Z_s : s \in I)$ 可测（即 X 是这些 Z_s 的函数），*
- *$Z_s \perp_P Y$ 对所有 $s \in I$ 成立，*

则 $X \perp_P Y$。

这个引理在数学上是显然的，但 **Mathlib 4 里没有**。它的严格证明需要 Dynkin π-系统定理：从" 每个生成元独立" 到" 整个 σ-代数上独立" 需要经过 π-λ 系统的论证。这个引理目前在代码里标为 `indepFun_of_forall_indep_generators`（sorry 状态），是整个 SVRGOuterLoop 证明的最大瓶颈。解决它需要单独向 Mathlib 贡献一个非平凡的测度论引理。

4.3 Epoch 收缩定理

定理 4.3 (Epoch 收缩，`svrg_epoch_contraction`)**.** *在 L-光滑、μ-强凸、$\eta\mu < 1$ 的条件下，令 $\rho = (1 - \eta\mu)^m + 4\eta L^2/\mu$，则：*

$$\mathbb{E}\big[\|w_{k+1} - w^*\|^2\big] \;\leq\; \rho \cdot \mathbb{E}\big[\|w_k - w^*\|^2\big] + \frac{\eta\sigma^2}{\mu}.$$

Lean 卡点. **双重可积性侧条件（Archetype B 特有的痛点）**。每次用 `integral_mono` 对期望做放缩，都需要显式证明被积函数 $\omega \mapsto \|w_{k+1}(\omega) - w^*\|^2$ 在 P 下可积。Lean 不会自动从" 过程结构" 推出可积性，必须把它作为假设 `h_int_inner` 和 `h_int_outer` 显式传进来。

单步算法（Archetype A）不用这么麻烦，因为方差有界直接给出可积性。但多轮算法（Archetype B）的迭代点是递归定义的，每一步的可积性都要单独处理——这导致每个定理签名里都多出两个假设，也让代码显得很冗长。

4.4 最终收敛率

定理 4.4 (SVRG 外层循环强凸收敛)**.** *在定理 ?? 的条件下，经过 K 个 epoch（每 epoch m 步）后：*

$$\mathbb{E}\big[\|w_K - w^*\|^2\big] \;\le\; (1-\eta\mu)^{mK}\,\|w_0 - w^*\|^2 + \frac{\eta\sigma^2}{\mu\big(1-(1-\eta\mu)^m\big)}.$$

证明思路：对定理 ?? 连用 K 次，展开得到：

$$\mathbb{E}[\|w_K - w^*\|^2] \;\le\; \rho^K\|w_0 - w^*\|^2 + \frac{\eta\sigma^2}{\mu}\sum_{j=0}^{K-1}\rho^j \;\le\; \rho^K\|w_0 - w^*\|^2 + \frac{\eta\sigma^2}{\mu(1-\rho)}.$$

把 ρ 的表达式代入化简即得。Lean 里需要用 `Finset.geom_sum_le` 或者手动处理有限几何级数。

5 卡点总结与关键路径

定理	Gap 类型	状态	预计工时
凸函数一阶条件（定理 ??）	L1：Mathlib 缺失	已证	3h
强凸一阶条件（定理 ??）	L1：Mathlib 缺失	已证	4h
凸内积下界（推论 ??）	L1 推论	已证	0.5h
强凸内积下界（推论 ??）	L1 推论	已证	0.5h
梯度范数估计（定理 ??）	L3：类型签名不匹配	已证	2h
SVRG 方差缩减（定理 ??）	L2：组合缺失	已证	3h
独立性组合（引理 ??）	**L2：Mathlib 缺失**	**Sorry**	>8h
Epoch 独立性（引理 ??）	L2：依赖上述引理	**Sorry**	4h
Epoch 收缩（定理 ??）	L2：双重可积性侧条件	**Sorry**	4h
外层收敛（定理 ??）	L2：几何级数	**Sorry**	2h

从 sorry 到完全证明的关键路径是：

$$\underbrace{\text{引理 ??}}_{\text{Dynkin } \pi\text{-系统，最难}} \implies \text{引理 ??} \implies \underbrace{\text{定理 ??}}_{+\text{ 显式可积性假设}} \implies \text{定理 ??}.$$

引理 ??（独立性组合）是唯一的”硬卡点”——其余 sorry 在它解决之后都是直接的，预计总工时 $\approx$ 10h。

6 难度与价值评估

6.1 难度分析

数学形式化本身：中高难度。每个算法大约需要 200–400 行 Lean 算法层代码，加上 50–150 行自定义胶水引理。Level 3 Gap（类型签名不匹配）数量多但每个都小，主要是需要熟悉 Mathlib

的具体 API，花时间但不需要新想法。Level 2 Gap（独立性组合）属于真正的研究级障碍，需要独立的测度论论证，不是查 Mathlib 能解决的。

API 学习成本：前期高，快速递减。第一个算法（SGD）需要大量探索 Mathlib 命名约定。到第三个算法（SVRG），已积累 30+ 可复用胶水引理，新引理的需求量降低了约 60%。

自动化可靠性：中等。目前多智能体编排系统（5 个 Agent 协作）在 Archetype A（单步）算法上能稳定让 sorry 数量单调减少。Archetype B（多 epoch）算法在遇到 Level 2 Gap 时需要人工介入。

6.2 价值评估

首创性：明确的”第一”。目前没有任何工作在任何交互式定理证明器里机器验证了 SGD、SVRG 或相关算法的收敛性定理。这是一个清晰的学术空白。

可复用性：胶水层越积越厚。`Lib/Glue/` 和 `Lib/Layer0/` 里的引理和算法无关。一旦建好，每个新算法只需要写桥接代码，不需要重新发展测度论基础。

自动化流水线：额外亮点。多智能体系统在非平凡数学证明上能取得可测量的进展，展示了 LLM 驱动的形式化验证的可行性，是论文的额外贡献点。

发表方向：

- 形式化验证方向：ITP、CPP、FMCAD——强匹配，”首次形式化随机优化”足够新颖。
- 机器学习方向：NeurIPS、ICML——可行，需要把自动化流水线作为主要贡献来写。
- 核心风险：sorry 全部填完需要时间，尤其是引理 **??** 的 Dynkin 论证。如果以”sorry-free proof”为卖点，这是主要时间风险点。

$$\alpha = \frac{N}{N-1}\times$$