SGD 收敛性的 Lean 4 形式化分析

证明架构、基础设施设计与 Mathlib 边界研究

基于 /SGD 代码库的深度分析

2026 年 3 月 6 日

目录

1 引言 **3**

1.1 项目背景 3

1.2 主要结果概览 3

1.3 文件架构 3

2 证明的核心难点与瓶颈 **4**

2.1 非正式证明与形式化之间的鸿沟 4

2.2 σ-代数格推理的形式化负担 4

2.3 可积性的全量追踪 5

2.4 期望层面的不等式推理 5

3 新建基础设施的作用与设计 **6**

3.1 `SmoothDescent.lean`：L-光滑的解析基础设施 6

3.1.1 背景：Mathlib 的现有工具与缺口 6

3.1.2 定理 1：沿线段的微积分基本定理 6

3.1.3 定理 2：L-光滑二次上界 6

3.2 `ConvexGradient.lean`：凸函数的几何基础设施 7

3.2.1 背景：多维凸一阶条件的缺失 7

3.2.2 定理 3：凸函数的一阶条件 7

3.2.3 定理 4：强凸函数的一阶条件 7

3.2.4 用于最小值点的推论 8

3.3 `IndepExpect.lean`：测度论深度最大的部分 8

3.3.1 核心证明链 8

3.3.2 定理 5：有界方差传递 8

3.3.3 定理 6：无偏交叉项等式 8

4 证明的主要思路与经典方法对比 9

4.1 经典 SGD 收敛证明的框架 9

4.2 非凸情形的完整证明链 9

4.3 强凸情形的完整证明链 10

4.4 与非正式证明的主要差异 11

5 数学自动化证明在随机优化中的瓶颈 11

5.1 瓶颈一：条件期望 API 的缺失 11

5.2 瓶颈二：可积性的自动推导 11

5.3 瓶颈三：期望不等式的 tactic 支持 12

5.4 瓶颈四：随机过程的 definitional equality 问题 12

6 Mathlib 对随机优化支持的边界 13

6.1 Mathlib 已有的工具（可直接使用） 13

6.2 Mathlib 缺失的工具（本项目自建） 13

6.3 Mathlib 的深层边界分析 14

6.3.1 维度一：抽象层次不匹配 14

6.3.2 维度二：随机过程理论的局限 14

6.3.3 维度三：计算层面的自动化 14

6.4 未来工作的边界与展望 14

7 总结 15

1 引言

1.1 项目背景

随机梯度下降（Stochastic Gradient Descent，SGD）是现代机器学习的核心算法之一。其收敛性分析已在数学文献中被充分研究，但将这些分析**机器验证**——即在交互式证明助手中给出完整的形式化证明——仍是数学形式化领域的前沿挑战。

本代码库（`/SGD`）在 Lean 4 + Mathlib 框架下，对实 Hilbert 空间 E 上的 SGD 算法给出了三种经典收敛定理的完整形式化证明，覆盖了从非凸到强凸的完整难度谱系。

1.2 主要结果概览

表 1: 三种 SGD 收敛定理

定理	条件	收敛率	文件位置
`sgd_convergence_nonconvex`	L-光滑	$O(1/\sqrt{T})$，$\mathbb{E}\,\|\nabla f(w_t)\|^2$	Main.lean ğ8
`sgd_convergence_convex`	L-光滑 + 凸	$O(1/\sqrt{T})$，$\mathbb{E}[f(w_t) - f^*]$	Main.lean ğ9
`sgd_convergence_strongly_convex`	L-光滑 + μ-强凸	线性收敛	Main.lean ğ10

每个收敛定理均采用**两层结构**：

1. **一步引理**：对每次迭代建立期望进展的精确上界。
2. **收敛定理**：对一步引理求和/递推，通过望远镜求和或归纳得到最终界。

1.3 文件架构

整个代码库由四个 Lean 文件组成，其依赖关系如下：

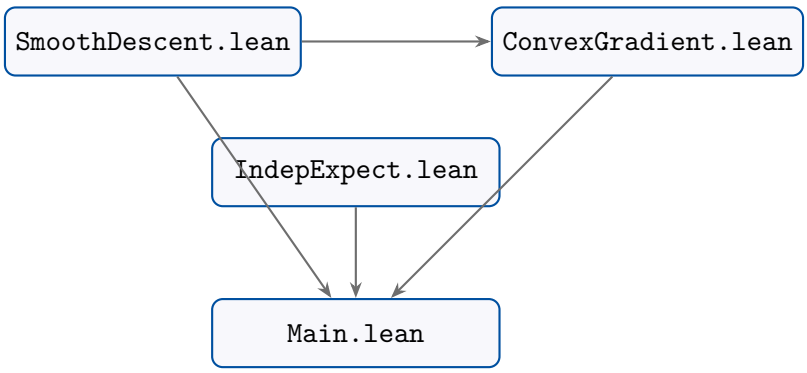

- **`SmoothDescent.lean`**：L-光滑函数的解析工具（FTC + 二次上界）
- **`ConvexGradient.lean`**：凸/强凸函数的一阶条件（依赖 SmoothDescent）

- `IndepExpect.lean`：独立性与期望分解的测度论工具
- `Main.lean`：SGD 定义、自然滤子、独立性引理、三个收敛定理

2 证明的核心难点与瓶颈

2.1 非正式证明与形式化之间的鸿沟

教材中 SGD 收敛分析的核心步骤通常写作：

> "对 ξ_t 取条件期望，利用 w_t 与 ξ_t 的独立性和梯度的无偏性，得到 $\mathbb{E}[\langle \nabla f(w_t), g_t \rangle] = \mathbb{E}[\|\nabla f(w_t)\|^2]$。"

这句话在非正式叙述中是完全平凡的。然而，要在 Lean 4 中形式化这一步，需要将其分解为 **至少五个独立的形式化步骤**：

1. **证明** $w_t \perp \xi_t$：w_t 只依赖 $\xi_0, \ldots, \xi_{t-1}$，必须通过自然滤子 $\mathcal{F}_t = \sigma(\xi_0, \ldots, \xi_{t-1})$ 和 `iIndepFun` 的 σ-代数格推理正式建立（见 `sgdProcess_indepFun_xi`，Main.lean 第 171–209 行）。
2. **将联合分布分解为乘积测度**：利用 Mathlib 的等价刻画 `indepFun_iff_map_prod_eq_prod_map_m` 将
$$P \circ (w_t, \xi_t)^{-1} = (P \circ w_t^{-1}) \otimes \nu$$
作为显式命题证明（IndepExpect.lean 第 61–62 行）。
3. **应用 Bochner-Fubini 定理**：通过 `integral_prod` 将乘积测度上的积分分解为迭代积分，需要显式验证可积性条件。
4. **应用无偏性假设**：在 Fubini 之后的内层积分中，调用 $\int_S \nabla L(w, s)\, d\nu(s) = \nabla f(w)$，通过 `integral_inner` 将 $h(w)$ 拉出内积后应用。
5. **将结果推回原测度**：通过 `integral_map` 将 $P \circ w_t^{-1}$ 上的积分还原到 P 上的积分。

这五步的总实现体现在 IndepExpect.lean 的两个核心定理中，构成了整个证明库的测度论核心。

2.2 σ-代数格推理的形式化负担

以 `sgdProcess_indepFun_xi` 为例，其证明展示了 σ-代数格推理的繁琐性：

```
lemma sgdProcess_indepFun_xi ... (t : N) :
    IndepFun (sgdProcess ... t) (x t) P := by
  -- 自然滤子 F_t = sup_{j < t} sigma(x_j)
```

```
  set F := sgdFiltration x hx_meas
  -- process t 关于 F t 可测
  have h_adapted : Measurable[F t] (sgdProcess ... t) := ...
  -- comap(process t) <= F t
  have h_comap_le : comap(process t) <= F t := ...
  -- F t 与 comap(x t) 独立（关键步骤）
  have h_filt_indep : Indep (F t) (comap (x t)) P := by
    -- 利用指标集不相交：{j | j < t} 与 {t} 不相交
    have h_disj : Disjoint {j | j < t} {t} := ...
    exact indep_iSup_of_disjoint h_le h_iIndep h_disj
  -- 单调性：comap(process t) <= F t => 继承独立性
  exact indep_of_indep_of_le_left h_filt_indep h_comap_le
```

注意这段代码的数学内容（“wt 只依赖过去的样本”）是完全平凡的，但其形式化需要在 MeasurableSpace 的上确界格（iSup）上做精确的格运算，并显式处理 comap、Indep、iIndep 三个不同层次的独立性概念之间的关系。

2.3 可积性的全量追踪

Lean 中每次使用积分线性性（$\int(f+g) = \int f + \int g$）都需要提供 f 和 g 的可积性证明。这导致每个一步引理的函数签名携带大量 Integrable 假设。以 stochastic_descent_nonconvex 为例，其签名需要：

```
(h_int_ft  : Integrable (fun o => f (process t o)) P)
(h_int_ft1 : Integrable (fun o => f (process (t+1) o)) P)
(h_int_inner : Integrable (fun o =>
    <gradF (process t o), gradL (process t o) (x t o)>_R) P)
(h_int_sq   : Integrable (fun o =>
    ||gradL (process t o) (x t o)||^2) P)
(h_int_gF_sq : Integrable (fun o =>
    ||gradF (process t o)||^2) P)
```

这七个可积性假设在教材中被隐式假定，而在 Lean 中必须由调用方逐一提供。更根本的问题是，Mathlib 目前缺乏针对 SGD 迭代结构的**自动可积性传播**工具。

2.4 期望层面的不等式推理

形式化证明中大量出现对积分的估计，例如：

$$\int \langle \nabla f(w_t), \nabla f(w_t) \rangle \, dP \leq \int \sigma^2 \, dP$$

这类不等式不能直接被 `linarith` 处理，需要手动调用 `integral_mono`，并为每次调用提供被积函数的可测性和被积函数的逐点不等式。在随机优化中，这类期望不等式链远多于普通标量不等式链，显著增加了证明的技术负担。

3 新建基础设施的作用与设计

三个辅助文件共同构成了一个**随机优化分析的小型基础库**。这个库在 Mathlib 主库中是缺失的，是本代码库得以完成完整形式化证明的关键。

3.1 `SmoothDescent.lean`：L-光滑的解析基础设施

3.1.1 背景：Mathlib 的现有工具与缺口

Mathlib 提供了 `HasGradientAt`（函数在一点处有梯度）和 `LipschitzWith`（Lipschitz 连续性），但没有将二者连接起来的关键结果：L-光滑函数的二次上界。

3.1.2 定理 1：沿线段的微积分基本定理

定义 3.1. *设 $f : E \to \mathbb{R}$ 在每点 w 处有梯度 $\nabla f(w)$，∇f 连续。则对任意 $x, d \in E$：*

$$f(x+d) - f(x) = \int_0^1 \langle \nabla f(x + t \cdot d),\, d \rangle \, dt$$

该结果（`integral_inner_gradient_segment`）在 Mathlib 中完全缺失。证明分两步：

1. 证明 $\varphi(t) = f(x+t\cdot d)$ 在每个 t 处有导数 $\langle \nabla f(x+t\cdot d),\, d\rangle$（通过 `hasDerivAt_comp_lineSegment`，利用 f 的 Fréchet 导数与线段参数化的链式法则，再经 `toDual_apply_apply` 转换）。
2. 将标量版本的微积分基本定理 `intervalIntegral.integral_eq_sub_of_hasDerivAt` 应用于 φ。

3.1.3 定理 2：L-光滑二次上界

定理 3.2 (`lipschitz_gradient_quadratic_bound`)**.** *若 ∇f 是 L-Lipschitz 的，则对任意 $x, d \in E$：*

$$f(x+d) \le f(x) + \langle \nabla f(x),\, d \rangle + \frac{L}{2} \|d\|^2$$

证明思路. 将线段 FTC 的被积函数拆分：

$$\langle \nabla f(x + t \cdot d),\, d \rangle = \langle \nabla f(x),\, d \rangle + \underbrace{\langle \nabla f(x + t \cdot d) - \nabla f(x),\, d \rangle}_{\text{余项}}$$

对余项应用 Cauchy-Schwarz + Lipschitz 条件：

$$\langle \nabla f(x+t\cdot d)-\nabla f(x),\, d\rangle \le \|\nabla f(x+t\cdot d)-\nabla f(x)\|\cdot\|d\| \le L\cdot t\cdot \|d\|^2$$

对 $t\in[0,1]$ 积分，得余项贡献 $\le \int_0^1 L\cdot t\cdot\|d\|^2\,dt = \frac{L}{2}\|d\|^2$。 □ □

该定理是非凸收敛定理中 `descent_lemma` 的直接来源。

3.2 `ConvexGradient.lean`：凸函数的几何基础设施

3.2.1 背景：多维凸一阶条件的缺失

Mathlib 有 `ConvexOn`（凸函数）和 `StrongConvexOn`（强凸函数）的完整定义，以及一维情形的切线不等式。但**多维（Hilbert 空间）版本的一阶最优性条件**缺失：

$$f \text{ 凸} + \text{可微} \implies f(y)\ge f(x)+\langle \nabla f(x),\, y-x\rangle$$

3.2.2 定理 3：凸函数的一阶条件

定理 3.3 (`convex_first_order_condition`). *设 $f:E\to\mathbb{R}$ 在 $univ$ 上凸，且 ∇f 处处存在，则对任意 $x,y\in E$：*

$$f(y)\ge f(x)+\langle \nabla f(x),\, y-x\rangle$$

证明思路. 构造 $g(t)=f(x+t\cdot(y-x))$。通过 `ConvexOn.comp_affineMap` 证明 g 在 $\mathbb{R}$ 上凸（归约到标量情形）。对 g 应用 Mathlib 的标量版本切线不等式 `ConvexOn.le_slope_of_hasDerivAt`：

$$g'(0)\le \frac{g(1)-g(0)}{1-0}$$

利用 `hasDerivAt_comp_lineSegment`（来自 SmoothDescent.lean），识别出 $g'(0)=\langle \nabla f(x),\, y-x\rangle$，$g(0)=f(x)$，$g(1)=f(y)$。 □ □

3.2.3 定理 4：强凸函数的一阶条件

定理 3.4 (`strong_convex_first_order_condition`). *设 f 是 μ-强凸的，∇f 处处存在，则：*

$$f(y)\ge f(x)+\langle \nabla f(x),\, y-x\rangle+\frac{\mu}{2}\|y-x\|^2$$

证明思路. 令 $h(w)=f(w)-\frac{\mu}{2}\|w\|^2$。由 `strongConvexOn_iff_convex`，$h$ 是普通凸函数。h 的梯度为 $\nabla h(w)=\nabla f(w)-\mu\cdot w$（通过 `hasStrictFDerivAt_norm_sq` 推出 $\nabla(\|\cdot\|^2/2)=\mathrm{id}$，再缩放）。对 h 应用凸 FOC，然后用 `norm_sub_sq_real` 的代数恒等式化简。 □ □

3.2.4 用于最小值点的推论

这两个 FOC 各有一个针对最小值点 w^* 的推论，是各一步引理的直接组件：

推论 3.5 (`convex_inner_lower_bound`). $\langle \nabla f(w),\, w - w^* \rangle \geq f(w) - f(w^*)$

推论 3.6 (`strong_convex_inner_lower_bound`). $\langle \nabla f(w),\, w - w^* \rangle \geq \frac{\mu}{2} \|w - w^*\|^2$

3.3 `IndepExpect.lean`：测度论深度最大的部分

这是整个证明库中**技术难度最高**的组件。git 历史显示，这两个定理最初用 `sorry` 跳过，最新版本完成了完整的实现。

3.3.1 核心证明链

两个定理共享一个统一的证明模式：

$$\int_\Omega F(w_t(\omega), \xi_t(\omega))\, dP$$

$\downarrow$ `integral_map`

$$\int_{E\times S} F(w,s)\, d[P \circ (w_t, \xi_t)]$$

$\downarrow$ `IndepFun` $\Rightarrow$ 乘积测度

$$\int_{E\times S} F(w,s)\, d[(P \circ w_t^{-1}) \otimes \nu]$$

$\downarrow$ `integral_prod` (Fubini)

$$\int_E \left(\int_S F(w,s)\, d\nu\right) d(P \circ w_t^{-1})$$

$\downarrow$ 逐点估计 / `integral_inner` + 无偏性

结论（逐点 bound 或 unbiasedness）

3.3.2 定理 5：有界方差传递

定理 3.7 (`expectation_norm_sq_gradL_bound`). *若 $\mathbb{E}_\nu[\|\nabla L(w,\cdot)\|^2] \leq \sigma^2$ 对所有 w 成立，且 $w_t \perp \xi_t$，$P \circ \xi_t^{-1} = \nu$，则：*

$$\mathbb{E}_P\Big[\|\nabla L(w_t, \xi_t)\|^2\Big] \leq \sigma^2$$

关键步骤是将 P 上的可积性假设搬运到乘积测度 $(P \circ w_t^{-1}) \otimes \nu$ 上（通过 `integrable_map_measure` + `h_prod_eq`），然后利用 `integral_prod_left` 和 `integral_mono` 完成逐点估计的积分。

3.3.3 定理 6：无偏交叉项等式

定理 3.8 (`expectation_inner_gradL_eq`). *对任意可测函数 $h : E \to E$，若 $w_t \perp \xi_t$，梯度无偏，则：*

$$\mathbb{E}_P\Big[\langle h(w_t),\, \nabla L(w_t, \xi_t)\rangle\Big] = \mathbb{E}_P\Big[\langle h(w_t),\, \nabla f(w_t)\rangle\Big]$$

Fubini 展开后，内层积分变为 $\int_S \langle h(w), \nabla L(w,s)\rangle \, d\nu(s)$。此时调用 `integral_inner`（Bochner 积分的内积线性性）将 $h(w)$ 从积分中拉出：

$$\int_S \langle h(w), \nabla L(w,s)\rangle \, d\nu(s) = \langle h(w), \int_S \nabla L(w,s) \, d\nu(s)\rangle = \langle h(w), \nabla f(w)\rangle$$

最后通过 `integral_map`（反向）将 $P \circ w_t^{-1}$ 上的积分还原到 P 上。

4 证明的主要思路与经典方法对比

4.1 经典 SGD 收敛证明的框架

本代码库的证明结构与经典文献（如 Bottou、Curtis、Nocedal 2018）的框架**完全一致**，采用逐层递进的分析策略：

表 2: 三种收敛定理的经典证明框架

情形	关键量	一步引理	全局工具
非凸	$\mathbb{E}[\|\nabla f(w_t)\|^2]$	L-光滑下降 + 期望	望远镜求和 + 除以 T
凸	$\mathbb{E}[f(w_t) - f^*]$	距离平方扩展 + 凸 FOC	望远镜 + 弃非负项
强凸	$\mathbb{E}[\|w_t - w^*\|^2]$	强凸 FOC 给出压缩	归纳展开 + 等比级数

4.2 非凸情形的完整证明链

一步引理（`stochastic_descent_nonconvex`）的证明策略：

1. **逐点下降**（来自 `descent_lemma`，完全利用 **`SmoothDescent.lean`**）：对每个 ω，

$$f(w_t - \eta \cdot g_t) \le f(w_t) - \eta \langle \nabla f(w_t), g_t\rangle + \frac{L}{2}\eta^2 \|g_t\|^2$$

2. **对 Ω 积分**：利用积分的单调性 `integral_mono`（需要逐项可积性）。

3. **无偏性简化**（来自 `expectation_inner_gradL_eq`，$h = \nabla f$）：

$$\mathbb{E}[\langle \nabla f(w_t), g_t\rangle] = \mathbb{E}[\langle \nabla f(w_t), \nabla f(w_t)\rangle] = \mathbb{E}[\|\nabla f(w_t)\|^2]$$

4. **有界方差**（来自 `expectation_norm_sq_gradL_bound`）：$\mathbb{E}[\|g_t\|^2] \le \sigma^2$

收敛定理（sgd_convergence_nonconvex）的证明策略：

对一步界从 $t = 0$ 到 $T - 1$ 求和，利用望远镜：

$$\sum_{t=0}^{T-1} \Big(\mathbb{E}[f(w_{t+1})] - \mathbb{E}[f(w_t)] \Big) = \mathbb{E}[f(w_T)] - f(w_0)$$

用 $\mathbb{E}[f(w_T)] \geq f^*$ 给出下界，整理后除以 ηT：

$$\frac{1}{T} \sum_{t=0}^{T-1} \mathbb{E}[\|\nabla f(w_t)\|^2] \leq \frac{2(f(w_0) - f^*)}{\eta T} + \eta L \sigma^2$$

取 $\eta \sim 1/\sqrt{T}$ 即得 $O(1/\sqrt{T})$ 收敛率。

在 Lean 中，望远镜求和通过 `Finset.sum_range_sub` 和求和重写实现：

```
have h_tele : sum_{t in range T} (a t - a (t+1)) = a 0 - a T :=
   by
  simp_rw [show forall t, a t - a(t+1) = -(a(t+1) - a t) from
     ...]
  rw [Finset.sum_neg_distrib, Finset.sum_range_sub]; ring
```

4.3 强凸情形的完整证明链

强凸情形展示了形式化证明的一个优雅之处：归纳步骤的噪声累积代数恒等式。

一步压缩引理（one_step_progress_sc）给出：

$$\mathbb{E}[\|w_{t+1} - w^*\|^2] \leq (1 - \eta\mu)\, \mathbb{E}[\|w_t - w^*\|^2] + \eta^2 \sigma^2$$

展开递推通过归纳证明（sgd_convergence_strongly_convex），归纳步骤的关键是以下代数恒等式（由 `field_simp; ring` 自动验证）：

$$(1 - \eta\mu) \left[(1 - \eta\mu)^T \|w_0 - w^*\|^2 + \frac{\eta\sigma^2}{\mu} \right] + \eta^2 \sigma^2 = (1 - \eta\mu)^{T+1} \|w_0 - w^*\|^2 + \frac{\eta\sigma^2}{\mu}$$

这个恒等式的成立本质上是等比级数求和 $\sum_{k=0}^{T-1} (1 - \eta\mu)^k \leq \frac{1}{\eta\mu}$ 被代数地吸收进递推式中，无需单独证明等比级数的显式公式。

4.4 与非正式证明的主要差异

表 3: 非正式证明 vs. 形式化证明：关键差异

步骤	非正式写法	形式化所需
条件期望分解	“由独立性，取期望可分解”	`sgdProcess_indepFun_xi` + `IndepExpect.lean`（∼200 行）
凸一阶条件	“由凸性的一阶条件”	`ConvexGradient.lean`（∼130 行）
L-光滑展开	“Taylor 展开加 Lipschitz 估计”	`SmoothDescent.lean`（∼170 行）
可积性	隐式假定	每个引理 5–8 个显式假设
等比级数	“几何级数收敛”	代数恒等式，`field_simp`; `ring`

5 数学自动化证明在随机优化中的瓶颈

5.1 瓶颈一：条件期望 API 的缺失

随机优化分析的核心语言是**条件期望**：

$$\mathbb{E}[f(w_t, \xi_t) \mid \mathcal{F}_t] = \mathbb{E}_\xi[f(w_t, \xi)] \quad \text{（当 } w_t \text{ 是 } \mathcal{F}_t\text{-可测时）}$$

Mathlib 中虽然有 `MeasureTheory.condExp`，但其 API 处于相对初级的阶段，与随机优化分析所需的操作模式（分解联合期望、交换求和与期望）之间存在巨大鸿沟。

本代码库**完全绕开了条件期望**，转而使用独立性 + Fubini + `integral_map` 的组合来实现等价效果。这种绕路方案本身是可行的，但产生了大量底层测度论代码，掩盖了原本简洁的概率论直觉。

注记 5.1. *理想中，一个完善的随机优化形式化库应该提供：*

$$\textit{condExp_of_indepFun} : w_t \perp \xi_t \implies \mathbb{E}[f(w_t, \xi_t) \mid w_t] = \mathbb{E}_\nu[f(w_t, \cdot)]$$

作为标准引理。这样"取条件期望"就能变成单步 rw，而非 50 行的测度论推导。

5.2 瓶颈二：可积性的自动推导

当前形式化中，每个一步引理都需要调用方提供 6–8 个 `Integrable` 假设。这些假设的证明在实践中通常是标准的，但 Mathlib 缺乏：

- **合成可积性推导**：若 w_t 可积且 f 连续，则 $f \circ w_t$ 可积（需要有界性假设，不是普遍成立的）。
- **SGD 迭代的矩传播**：若 $\mathbb{E}[\|w_t\|^2] < \infty$ 且梯度有有界方差，则 $\mathbb{E}[\|w_{t+1}\|^2] < \infty$。这需要专门的随机过程理论。
- **对流形结构的利用**：在 $\mathbb{R}^d$ 情形，许多可积性可以从有界性自动得出。

从自动化证明的角度看，这是一个**结构性瓶颈**：即使底层的不等式逻辑完全自动化，可积性假设的生成仍需要人工干预。

5.3 瓶颈三：期望不等式的 tactic 支持

标量不等式有 `linarith`、`nlinarith`、`positivity` 等强力 tactic。但对于期望不等式（$\mathbb{E}[X] \le \mathbb{E}[Y]$ 由 $X \le Y$ 逐点推出），目前只有底层的 `integral_mono`，需要手动提供：

1. 被积函数 X 的可积性
2. 被积函数 Y 的可积性
3. 逐点不等式 $\forall \omega, X(\omega) \le Y(\omega)$

这导致证明中大量如下模式的冗余代码：

```
have h_int3 : integral(f(w_{t+1})) <= integral(rhs) :=
  integral_mono h_int_ft1 h_int_rhs (fun o => h_step_eq o | h_pw
     o)
```

其中 `h_step_eq` 和 `h_pw` 都需要分别证明。一个理想的 tactic `exp_mono` 应当能自动处理这类模式。

5.4 瓶颈四：随机过程的 definitional equality 问题

`sgdProcess` 被定义为递归函数 $\mathbb{N} \to \Omega \to E$：

```
noncomputable def sgdProcess (w0 : E) (h : N   R) (gradL : E   S
     E) (x : N   O   S) :
    N   O   E
  | O     => fun _ => w0
  | t + 1 => fun o => sgdProcess ... t o - h t * gradL (
     sgdProcess ... t o) (x t o)
```

这种递归定义导致 `process (t+1) o` 在很多 tactic 中不能自动展开，需要显式的 `rfl` 或 `simp only [sgdProcess]`。更复杂的随机过程（如带动量的 SGD、Adam、有停时

的过程）将在这个框架下产生更严重的 definitional equality 问题，显著增加证明技术负担。

6 Mathlib 对随机优化支持的边界

6.1 Mathlib 已有的工具（可直接使用）

表 4: Mathlib 中已有的随机优化相关工具

领域	Mathlib 工具	在本项目中的用途
概率独立性	`IndepFun`, `iIndepFun`	SGD 样本的 IID 假设
独立性推断	`indep_iSup_of_disjoint`	由 IID 推出 $w_t \perp \xi_t$
乘积测度	`Measure.prod`	独立随机变量的联合分布
Bochner-Fubini	`integral_prod`	迭代期望
积分变量替换	`integral_map`	推前测度上的积分
积分线性性	`integral_inner`, `integral_add`	内积/求和拉出期望
凸分析	`ConvexOn`, `StrongConvexOn`	凸/强凸假设
凸函数操作	`comp_affineMap`	合成凸函数
强凸等价	`strongConvexOn_iff_convex`	强凸 FOC 的证明
Lipschitz 分析	`LipschitzWith`	L-光滑定义
滤子/适应性	`Filtration`, `Adapted`	自然滤子

6.2 Mathlib 缺失的工具（本项目自建）

表 5: Mathlib 缺失的工具与本项目的解决方案

缺失工具	本项目方案	来源文件
多维凸一阶条件	`convex_first_order_condition`	ConvexGradient.lean
多维强凸一阶条件	`strong_convex_first_order_condition`	ConvexGradient.lean
Hilbert 空间 FTC（梯度形式）	`integral_inner_gradient_segment`	SmoothSegment.lean
L-光滑二次上界	`lipschitz_gradient_quadratic_bound`	QuadraticBound.lean
有界方差传递	`expectation_norm_sq_grad_bound`	IndepExpBound.lean
无偏交叉项等式	`expectation_inner_grad_eq`	IndepExpect.lean
过程独立性	`sgdProcess_indepFun_xi`	Main.lean

6.3 Mathlib 的深层边界分析

当前 Mathlib 的随机分析能力可以用以下描述概括：

观察 6.1. *Mathlib 处于「**分析工具齐全但概率工具语言层次偏低**」的状态。Bochner 积分、测度论、Lipschitz 函数的工具相对完备，但专门针对「随机算法分析」模式的高层抽象几乎缺失。*

具体体现在以下三个维度：

6.3.1 维度一：抽象层次不匹配

随机优化分析需要在三个层次之间灵活切换：

1. **概率层**：$w_t \perp \xi_t$，$\mathbb{E}[\cdot \mid \mathcal{F}_t]$，大数定律
2. **测度论层**：σ-代数、Fubini、推前测度
3. **分析层**：Lipschitz 估计、凸分析、范数不等式

Mathlib 在第 2、3 层非常强，但第 1 层的高级接口（条件期望的可操作性）尚在发展中。每当需要从第 1 层下降到第 2 层时，产生大量样板代码。

6.3.2 维度二：随机过程理论的局限

Mathlib 有鞅（martingale）的基本理论，但缺乏：

- 关于 SGD/随机递推的专用工具
- 矩传播不等式（bounded moments under gradient updates）
- 停时和自适应步长的系统处理
- 随机过程的 convergence-in-probability 工具

6.3.3 维度三：计算层面的自动化

尽管 `ring`、`field_simp`、`positivity` 能处理许多代数验证，但涉及期望和积分的不等式链（如本项目中大量的 `linarith [h_var, h_foc, ...]`）需要大量手动设置中间量。一个专用的 `exp_ineq` tactic，能在积分不等式上做类似 `linarith` 的自动推理，将极大降低随机优化形式化的技术难度。

6.4 未来工作的边界与展望

基于当前代码库，可以自然延伸到的新定理包括：

- **带动量的 SGD**（Heavy Ball / Nesterov）：需要处理二阶递推，可沿用当前的 `IndepExpect.lean` 基础设施。
- **随机近端梯度下降**（PROX-SGD）：需要近端算子的形式化，Mathlib 目前有凸优化的近端框架但尚不完整。
- **Adam / RMSProp**：自适应步长引入了状态依赖的归一化项，当前的 `IsLSmooth` + 固定步长框架无法直接适用。
- **方差缩减方法**（SVRG、SARAH）：需要跟踪历史梯度的形式化，需要扩展 `SGDSetup` 结构。
- **分布式/联邦 SGD**：多个梯度源的独立性结构是当前 `iIndepFun` 框架的直接泛化，技术上可行。

7 总结

本代码库的核心贡献在于，在 Lean 4 + Mathlib 框架下完成了 SGD 三种收敛定理的完整机器验证，并在这一过程中揭示了以下重要洞察：

数学层面：三种收敛定理（非凸 $O(1/\sqrt{T})$、凸 $O(1/\sqrt{T})$、强凸线性收敛）的证明逻辑与经典文献完全一致，形式化过程没有引入新的数学内容，而是对已知证明的精确验证。

基础设施层面：三个辅助文件（**`SmoothDescent.lean`**、**`ConvexGradient.lean`**、**`IndepExpect.lean`**）填补了 Mathlib 在随机优化分析方向的关键空白，构成了一个可复用的小型基础库。

技术层面：形式化证明的最大挑战不是数学本身，而是：

1. 将非正式的 "取条件期望" 转化为五步测度论推导链
2. 管理大量显式的可积性假设
3. 在 σ-代数格上做精确的独立性推理

系统层面：Mathlib 目前处于 "分析工具完备、概率工具语言层次偏低" 的状态，条件期望 API 的完善和期望不等式专用 tactic 的开发，是提升随机优化形式化自动化程度的两个最关键的下一步。

本文档基于 `/SGD` 代码库（Lean 4 + Mathlib，2026）的深度分析生成。代码库包含 Main.lean（942 行）、IndepExpect.lean（161 行）、ConvexGradient.lean（131 行）、SmoothDescent.lean（171 行）四个文件，合计约 1400 行完整形式化证明。